
IPRE-DICOM

Arquitectura, entrenamiento y demostración reproducible

Pía Ayala · Avance técnico · septiembre de 2026

Prototipo local para visualizar imágenes médicas, ejecutar controles técnicos y organizar resultados sin afirmar validez clínica.

Qué problema intenta resolver

SITUACIÓN

- Las imágenes llegan en formatos, tamaños y convenciones diferentes.
- La calidad técnica, la privacidad y la clasificación requieren procesos distintos.
- Un experimento necesita trazabilidad para poder repetirse y compararse.

OBJETIVO DEL PROTOTIPO

Recibir una imagen, abrirla de forma uniforme, calcular indicadores, ejecutar checkpoints disponibles y devolver un informe estructurado mediante una API.

Uso previsto: investigación y apoyo técnico.

Qué existía y qué se implementó en este trabajo

DISPONIBLE AL COMENZAR

- Dos archivos de pesos: best_noise.pt y best_rotation.pt.
- No se dispone de logs, dataset de origen ni métricas verificables de esos pesos.
- CheXpert estaba almacenado en Calfuco, pero no conectado al código local.

IMPLEMENTADO E INTEGRADO

- API FastAPI y visor web.
- Lectores DICOM, raster, NIfTI y NumPy.
- Métricas, privacidad y anonimización experimental.
- MedMNIST, entrenamiento, W&B y pipeline IU.
- Demo reproducible y 26 pruebas automatizadas.

Conclusión metodológica: podemos demostrar integración y funcionamiento, pero no rendimiento clínico de los pesos existentes.

Estado verificable hoy

PROBADO LOCALMENTE

- API y visor
- Formatos y métricas
- Carga de noise/rotation
- PneumoniaMNIST entrenado
- 27 pruebas

IMPLEMENTADO, NO EJECUTADO

- Clasificador frontal/lateral
- Comparación con ResNet
- Registro W&B online
- Manifiesto IU

NO REALIZADO

- Despliegue en Calfuco
- Validación clínica
- OCR de píxeles
- Búsqueda vectorial

Arquitectura del repositorio

VISOR

`api/static/index.html`

Carga archivos y muestra
resultados

API

`api/main.py`

Rutas, validación y orquestación

SERVICIOS

`image_io.py` · `quality.py` · `privacy.py`

Lectura, métricas y auditoría

MODELOS

`medmnist_models.py` · MONAI

Carga checkpoints e inferencia

FLUJO

`agent_workflow.py`

Hallazgos y acciones acotadas

ENTRENAMIENTO

`scripts/train*.py`

Splits, métricas y checkpoints

Secuencia exacta de POST /predict



DECISIÓN DE DOMINIO

Los modelos generales solo se ejecutan para raster o DICOM CR/DX. NIfTI y NumPy reciben métricas, pero quedan fuera del dominio del clasificador de tórax.

Preprocesamiento por formato

Formato	Operación	Salida para la API
DICOM	PixelData, slope/intercept, ventana, MONOCHROME1	Imagen 2D + metadata resumida
Raster	Primera página y escala de grises	Imagen 2D
NIFTI	Descompresión y cortes centrales	Imagen 2D + shape/voxel spacing
NumPy	allow_pickle=False, cortes centrales, percentiles	Imagen 2D + dtype/shape
MedMNIST NPZ	Dataset completo	Se consulta por endpoints de dataset

Contratos de la API

Endpoint	Responsabilidad	Estado
GET /health	Dispositivo, modelos y datasets	Probado
GET /formats	Capacidades de entrada	Probado
POST /predict	Análisis técnico completo	Probado
POST /anonymize/dicom	Copia DICOM seudonimizada	Probado con fixtures
/datasets/medmnist/...	Descarga, catálogo y muestra	Probado con dataset real
/predict/medmnist/...	Inferencia MedMNIST	Sin checkpoint entrenado

Indicadores técnicos sin modelo

BRILLO

Promedio de intensidad normalizada.

CONTRASTE

Desviación estándar de intensidad.

RUIDO ESTIMADO

Mediana de la diferencia respecto de un suavizado local.

NITIDEZ ESTIMADA

Varianza de gradientes horizontales y verticales.


Estos valores permiten comparar entradas. Todavía no tienen umbrales clínicos calibrados.

Modelos disponibles en la ejecución local

Tarea	Checkpoint	Salida	Qué sabemos
Ruido	best_noise.pt	clean / noise	Carga y responde
Rotación	best_rotation.pt	clean / rotation	Carga y responde
Vista	best_view.pt	frontal / lateral	No existe aún
PneumoniaMNIST	medmnist_...pt	normal / pneumonia	Entrenado: 1 época
ChestMNIST	medmnist_...pt	14 probabilidades	No existe aún

No contamos con la procedencia ni métricas originales de los dos checkpoints existentes.

Cómo está diseñado el entrenamiento general



MÉTRICAS IMPLEMENTADAS

Accuracy, balanced accuracy, F1, ROC-AUC y classification report.

Estado: código y pruebas de split listos; no se ejecutó un nuevo entrenamiento completo en esta etapa.

Conceptos básicos del conjunto de datos

MUESTRA

Una imagen individual y su etiqueta. En PneumoniaMNIST la etiqueta 0 significa normal y la etiqueta 1 indica neumonía.

ETIQUETA

Respuesta conocida que el modelo intenta aprender. Durante el entrenamiento se compara la predicción con esta respuesta.

CONJUNTO MAESTRO

Colección completa antes de separar el experimento. El término técnico habitual es dataset; no es una sola imagen de referencia.

CLASE

Categoría posible de salida. Para PneumoniaMNIST existen dos clases: normal y neumonía.

La API no aprende al recibir una imagen. Solo aplica un modelo cuyos pesos deberían haberse aprendido antes.


Separación oficial de PneumoniaMNIST

Partición	Muestras	% del total	Normal	Neumonía	Uso
Train	4.708	80,4%	1.214	3.494	Ajustar pesos
Validation	524	8,9%	135	389	Elegir modelo
Test	624	10,7%	234	390	Medición final
Total	5.856	100%	1.583	4.273	Dataset maestro

El proyecto usa los splits incluidos por MedMNIST; no vuelve a mezclar estas 5.856 imágenes.

El desbalance importa: 73,0% del total corresponde a neumonía.

Qué ocurre durante una época de entrenamiento



ÉPOCA

Una pasada completa por todas las muestras de train. El script propone 10 épocas por defecto.

La validación se ejecuta al final de cada época. Sus imágenes no actualizan los pesos.

Estado real: este ciclo está programado, pero todavía no se ejecutó de principio a fin sobre PneumoniaMNIST.

Modelo, pérdida y optimización implementados

DENSENET121 DE MONAI

- Entrada de un canal en escala de grises.
- Salida binaria para PneumoniaMNIST.
- Reutiliza características mediante conexiones densas.

ACTUALIZACIÓN DE PESOS

Adam usa learning rate 0,0001.
CosineAnnealingLR lo reduce durante las 10 épocas.

BCEWITHLOGITSLLOSS

- Compara logits con etiquetas 0/1.
- Penaliza predicciones incorrectas.
- Permite una o varias etiquetas por imagen.

REPRODUCIBILIDAD

Semilla 42, configuración registrada y checkpoint con el mejor ROC-AUC de validación.

Train, validación y test cumplen funciones distintas

Partición	¿Actualiza pesos?	Pregunta que responde	Momento
Train	Sí	¿Qué patrones minimizan el error?	Cada batch
Validation	No	¿Qué época generaliza mejor?	Cada época
Test	No	¿Cómo rinde el modelo elegido?	Una vez al final

Usar test para escoger hiperparámetros contaminaría la evaluación final. El código reserva test hasta cargar el mejor checkpoint.

Métricas de clasificación y su significado

Métrica	Qué mide	Cuándo ayuda
Accuracy	% total de aciertos	Clases equilibradas
Balanced accuracy	Promedio del recall por clase	Clases desbalanceadas
F1	Equilibrio entre precisión y recall	Importan falsos positivos y negativos
ROC-AUC	Ordena positivos sobre negativos	Comparar discriminación entre modelos
Matriz de confusión	TP, TN, FP y FN	Entender el tipo de error

Probabilidad, accuracy y correlación no son equivalentes

PROBABILIDAD INDIVIDUAL

$P(\text{neumonía})=0,80$ significa que el modelo asignó 0,80 a esa clase para una imagen. No afirma 80% de aciertos globales.

ACCURACY DEL CONJUNTO

Porcentaje de muestras clasificadas correctamente después de fijar un umbral, normalmente 0,5.

CORRELACIÓN

Mide asociación entre variables. Este proyecto no usa correlación como métrica principal porque la tarea es clasificación.

ROC-AUC

Resume la discriminación para todos los umbrales. 0,5 equivale al azar y 1,0 a separación perfecta.

Los porcentajes reales solo podrán reportarse después de entrenar y evaluar el checkpoint nuevo.

Comparación de modelos considerada

Modelo	Fortaleza	Costo	Uso en este proyecto
DenseNet121	Buen extractor para radiografías	Medio	Implementado con MONAI
ResNet18/50	Baseline simple y conocido	Bajo/medio	Comparación pendiente
ViT	Contexto global	Alto; necesita más datos	No implementado
CLIP	Embeddings texto-imagen	Alto	Exploración futura
DINO	Embeddings sin etiquetas	Alto	Clustering futuro
kNN	Búsqueda por similitud	Depende del índice	No entrenado

La elección actual es DenseNet121 porque MONAI ya ofrece una implementación médica reproducible y compatible con imágenes de un canal.

Qué se hizo y qué falta para comparar modelos

REALIZADO

- DenseNet121 entrenada una época.
- Splits oficiales de MedMNIST.
- Checkpoint seleccionado por ROC-AUC.
- Evaluación final sobre test.
- Predicción verificada desde la API.

PENDIENTE

- Completar más épocas en Calfuco.
- Guardar curvas de múltiples épocas.
- Repetir con varias semillas.
- Entrenar ResNet con el mismo split.
- Comparar AUC, F1, tiempo y memoria.

La corrida inicial ya entrega resultados observados. La comparación entre arquitecturas sigue pendiente.

Resultados del entrenamiento real

Medición	Validación	Test	Interpretación
ROC-AUC	0,9912	0,9478	Buena discriminación inicial
F1	0,9398	0,8337	Baja al generalizar
Accuracy	No calculada	0,8542	85,42% de aciertos
Loss de train	0,2315	No aplica	Error de la época 1

DenseNet121, una época, 4.708 train, 524 validación y 624 test. Entrada original 28 x 28 redimensionada a 64 x 64.

Interpretación de los resultados obtenidos

LO QUE INDICAN

- ROC-AUC de test 0,9478: el ranking entre clases es prometedor.
- F1 de test 0,8337: precisión y recall todavía tienen errores.
- Accuracy 85,42%: 533 de 624 decisiones serían correctas con umbral 0,5.

LO QUE NO DEMUESTRAN

- No validan uso clínico.
- Una época no prueba convergencia.
- Una sola semilla no mide variabilidad.
- No existe aún comparación experimental con ResNet.

El ROC-AUC bajó 0,0434 entre validación y test. La diferencia justifica evaluar siempre en datos separados.

Por qué se usa source_id

SPLIT INCORRECTO

Original en train

Copia ruidosa de la misma imagen en validación

Resultado optimista por fuga

SPLIT AGRUPADO

Todas las variantes de una fuente quedan juntas

Train y validación contienen fuentes diferentes

Evaluación más honesta

GroupShuffleSplit usa source_id, paciente o estudio como unidad de separación.

Integración real de PneumoniaMNIST

DATASET INSTALADO

- Archivo: data/medmnist/pneumoniamnist.npz
- Fuente oficial: Zenodo
- MD5 verificado: 28209eda62fec6e6a2d98b1501bb15f
- Tamaño disponible: 28 x 28

ENDPOINT PROBADO

- Split: test
- Índice: 0
- Respuesta HTTP: 200
- Muestras del test: 624
- Etiqueta devuelta: [1]
- Contenido: image/png

El explorador web mostró: “Muestra 0 de 624 · etiquetas [1]”.

Qué significa MedMNIST dentro del proyecto

SÍ SE USA PARA

- Probar descarga y catálogo de datasets.
- Visualizar muestras de splits oficiales.
- Implementar un entrenador binario y multietiqueta.
- Definir el formato de checkpoints e inferencia.

NO RESUELVE

- Lectura de metadata DICOM.
- Anonimización de pacientes.
- Validación del modelo de ruido existente.
- Entrenamiento frontal/lateral.


El checkpoint PneumoniaMNIST ya está cargado: `/predict/medmnist` devuelve probabilidades normal y pneumonia.

Casos preparados para la demostración




Original

PneumoniaMNIST test #0



Rotada

25 grados



Ruidosa

Ruido gaussiano sigma 35

Además se generó un volumen NPY artificial para comprobar lectura 3D y exclusión de modelos fuera de dominio.

Resultados reales de POST /predict

Caso	Ruido estimado	P(noise)	P(rotation)	¿Modelos?
Original	0.0000	0.9465	0.4261	Sí
Rotada 25°	0.0000	0.9492	0.4278	Sí
Ruidosa	0.0588	0.9943	0.4699	Sí
Volumen NPY	0.0000	-	-	No

Ejecución local en CPU con los checkpoints presentes en models/.

Hallazgos de la demostración

FUNCIONÓ

- Los cuatro archivos recibieron HTTP 200.
- El ruido determinista distinguió la variante ruidosa: 0.0588 frente a 0.0000.
- NPY quedó fuera del dominio de los modelos, como estaba diseñado.
- El informe LangGraph se produjo de manera reproducible.

PROBLEMAS ENCONTRADOS

- $P(\text{noise})$ fue 0.9465 incluso en la original: alto falso positivo.
- La rotada quedó bajo el umbral 0.5: el modelo no detectó el caso.
- No se pueden inferir métricas globales con tres imágenes.
- Los pesos requieren procedencia, dataset y validación.

Conclusión del experimento local

La infraestructura funciona

La API abre los formatos, ejecuta los módulos, aplica reglas de dominio y devuelve resultados estructurados.

Los modelos aún no son confiables

La demo evidencia falsos positivos de ruido y baja sensibilidad a la rotación. El siguiente trabajo debe centrarse en datos, etiquetas y evaluación.

Privacidad y anonimización DICOM

AUDITORÍA

- Busca campos como PatientName, PatientID e InstitutionName.
- Devuelve nombres de campos, nunca sus valores.
- Evalúa BurnedInAnnotation y exige revisión de píxeles.

EXPORTACIÓN EXPERIMENTAL

- Elimina tags privados.
- Vacía identificadores directos conocidos.
- Remapea UUIDs con HMAC estable.
- No modifica PixelData.

Sin OCR ni redacción de píxeles. No equivale a certificación DICOM PS3.15.

Flujo agente: qué hace y qué no hace

ENTRADA

- Probabilidades ya calculadas
- Conteo de identificadores
- Bandera de revisión de píxeles

SALIDA

- Estado ok o review
- Hallazgos estructurados
- Acciones recomendadas
- Aviso no diagnóstico

LangGraph solo orquesta una función determinista. No usa un LLM, no clasifica imágenes y no toma decisiones clínicas.

Pruebas automatizadas

27

pruebas aprobadas

0

fallos actuales

COBERTURA PRINCIPAL

- Formatos y extensiones
- Privacidad y anonimización
- MedMNIST y métricas
- Split agrupado
- Manifiesto IU
- Endpoints HTTP
- Flujo agente

Comando: `python -m unittest discover -s tests -v`

Entrenamiento MedMNIST ejecutado

CONFIGURACIÓN

- PneumoniaMNIST o ChestMNIST
- Tamaños 28, 64, 128 o 224
- DenseNet121 con un canal
- BCEWithLogitsLoss
- Adam y cosine scheduler

EVALUACIÓN

- ROC-AUC macro
- F1 macro
- Exactitud por etiqueta
- Selección por validación
- Evaluación final en test

Corrida inicial: 1 época, ROC-AUC test 0,9478, F1 test 0,8337 y accuracy test 0,8542.

W&B: qué se preparó

REGISTRO POR ÉPOCA

- Pérdida
- Learning rate
- Accuracy y balanced accuracy
- F1 y ROC-AUC

TRAZABILIDAD

- Hiperparámetros
- Semilla y dispositivo
- Método de split
- Mejor checkpoint como artefacto
- Modo online u offline

La corrida inicial guardó métricas y checkpoint local. W&B sigue probado solo mediante un smoke test offline.

Pipeline frontal/lateral con IU Chest X-Ray



La vista lateral es una categoría válida, no una alerta de mala calidad.

Estado: generador de manifiesto y entrenamiento listos; dataset y entrenamiento todavía pendientes.

Calfuco: recursos inspeccionados, despliegue pendiente

OBSERVADO POR SSH

- RTX 3090 de 24 GB y dos RTX 2080 Ti
- 125 GB de RAM
- /mnt/data para datasets
- /mnt/workspace para entrenamiento
- Python del sistema 3.6.9

BLOQUEOS

- Sin permiso en /mnt/workspace/pfayala
- Sin acceso al daemon Docker
- Falta entorno Python moderno
- Proyecto aún no copiado ni ejecutado

Estado correcto para presentar: plan documentado, no despliegue realizado.

Cómo ejecutar la demostración

TERMINAL 1

```
source .venv/bin/activate
```

```
MEDMNIST_ROOT=data/medmnist python -m uvicorn  
api.main:app --host 127.0.0.1 --port 8000
```

TERMINAL 2

```
python scripts/run_demo.py
```

```
Guarda demo_assets/demo_results.json
```

NAVEGADOR

- Abrir <http://127.0.0.1:8000>
- Cargar original, rotada y ruidosa
- En MedMNIST: PneumoniaMNIST / test / 28 / índice 0

Guion de la demo en vivo

1 Abrir /health

Mostrar CPU y modelos rotation/noise.

3 Imagen original

Explicar métricas y falso positivo de ruido.

5 Imagen ruidosa

Comparar noise_estimate 0.0588 y P(noise) 0.9943.

2 Explorador MedMNIST

Mostrar test #0 de 624, etiqueta [1].

4 Imagen rotada

Mostrar que el modelo no cruza 0.5.

6 Volumen NPY

Mostrar lectura y exclusión de modelos.

Conclusión

Se implementó y probó una plataforma local modular.

La demostración confirmó formatos, reglas de dominio, MedMNIST y respuestas estructuradas.

El nuevo modelo PneumoniaMNIST alcanzó ROC-AUC 0,9478 y accuracy 85,42% en test tras una época.

Siguiente hito: completar más épocas y comparar DenseNet121 con ResNet usando exactamente los mismos splits.

Preguntas